

Predicting Advertisement Demand on Avito Platform

Artur Zagitov, Ildar Zaliyev, Artem Nazarov





Business problem

Sellers often struggle to predict demand for their products.

This leads to:

- Underpricing and lost revenue
- Overpricing and low buyer interest
- Frustration for both buyers and sellers

Avito 🔍 Все категории Поиск по объявлениям Найти

Главная > Электроника > Товары для компьютера

Продажа товаров для компьютера в Республике Татарстан 41 254

Фильтры

Электроника

Товары для компьютера

- Комплектующие
- Мониторы и запчасти
- Сетевое оборудование
- Клавиатуры и мыши
- Аксессуары
- Джойстики и рули
- Флешки и карты памяти
- Акустика
- Переносные жесткие диски
- Веб-камеры
- ТВ-тюнеры

Состояние

Любое Новое Б/у


Цена, ₽

От до


Продавцы

Все Частные Компании


IT Сортировка Сначала из Республики Татарстан



Moza HGP Shifter
13 000 ₽
Новый! Шифтер (рычаг переключения передач) на 7 передач + задняя. Один из лучших шифтеров, очень надежен.
Доставка от 1 дня
1 неделю назад ↑



Кабель витая пара Ftp медный
7 000 ₽
Витая пара кадена медный. Могу отрезать под нужный размер.
Доставка от 1 дня
6 дней назад ↑



Игровая Беспроводная мышка Dareu EM901
3 749 ₽
Облегченная двухрежимная мышь Dareu Wrangel EM901. Белоголубого цвета отличный вариант для тех, кому нужна легкая и качественная игровая мышь, поддерживает два режима питания провод и 2.4G, это дает преимущество в виде частоты опроса в 100...
Доставка от 1 дня
2 дня назад ↑



Business understanding

Business Objectives:

- Improve ad listing efficiency.
- Reduce underpriced and overpriced ads.
- Enhance user satisfaction and platform engagement.

ML Objectives:

- Develop a machine learning model to predict ad deal probability.
- Achieve a Root Mean Squared Error (RMSE) of 0.25 or lower on unseen data.

Success Criteria:

Business: Increased transaction volume and user engagement.

ML: RMSE below 0.25 on a held-out test dataset.



Data Description

- **Size:** 1.5 million records
- **Source:** Avito platform, accessed via Kaggle
- **Features:** Ad title, description, price, category, region, user type, and more.
- **Target:** Deal Probability - [0, 1]

Δ region	Δ city	Δ parent_categ...	Δ category_na...	Δ param_1	Δ param_2	Δ param_3	Δ title	Δ description	# price	# item_seq_nu...	📅 activation_da...	Δ user_type	# image_top_1	# deal_probabi...
Свердловская область	Екатеринбург	Личные вещи	Товары для детей и игрушки	Постельные принадлежности			Кокоби(кокон для сна)	Кокон для сна малыша, пользова лись меньше месяца.цвет серый	400.0	2	2017-03-28	Private	1000.0	0.12789
Самарская область	Самара	Для дома и дачи	Мебель и интерьер	Другое			Стойка для Одежды	Стойка для одежды, под вешалки. С бутика.	3000.0	19	2017-03-26	Private	692.0	0.0
Ростовская область	Ростов-на-Дону	Бытовая электроника	Аудио и видео	Видео, DVD и Blu-ray плееры			Philips bluray	В хорошем состоянии, домашний кинотеатр с blu ray, USB. Если настроить, то работает смарт тв / Торг	4000.0	9	2017-03-20	Private	3032.0	0.43177
Татарстан	Набережные Челны	Личные вещи	Товары для детей и игрушки	Автомобильные кресла			Автокресло	Продам кресло от8-25кг	2200.0	286	2017-03-25	Company	796.0	0.80323
Волгоградская область	Волгоград	Транспорт	Автомобили	С пробегом	ВАЗ (LADA)	2110	ВАЗ 2110, 2003	Все вопросы по телефону.	40000.0	3	2017-03-16	Private	2264.0	0.20797




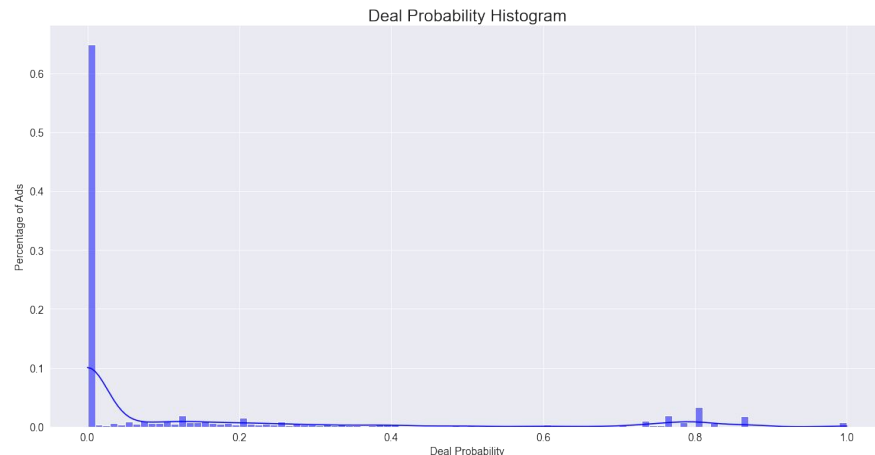
EDA - Missing values





EDA - Target

- More than 66% of ad listings has deal probability of less than 0.05 (5%)
- More than 88% of ad listings has deal probability of less than 0.50 (50%)
- A small peak around 0.8, indicating a smaller number of ads with higher, deal probabilities.

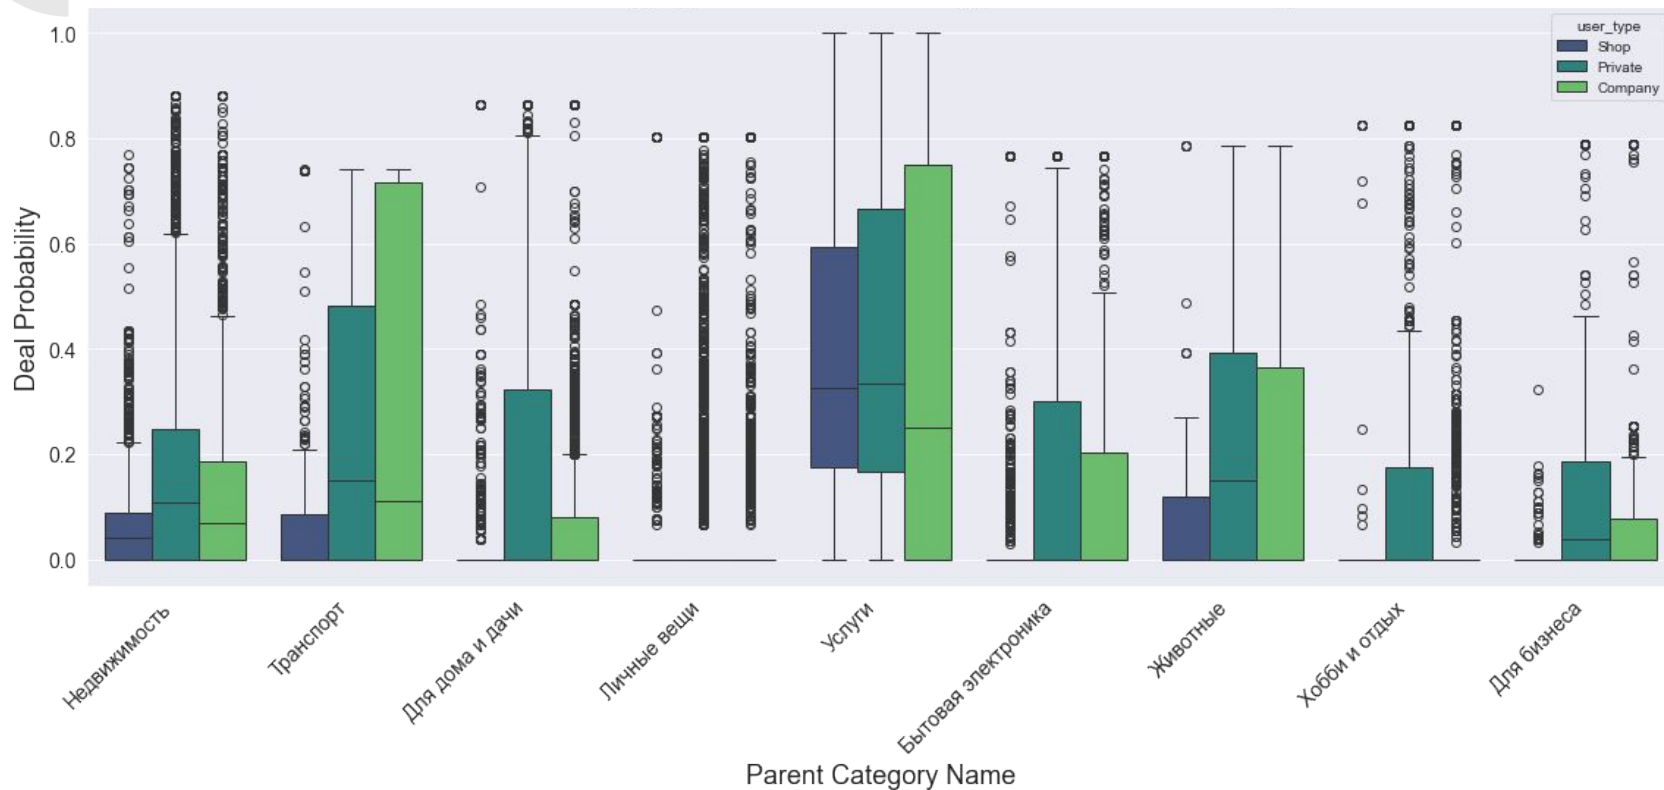





EDA - Price vs Target



EDA - User Type and Parent Category vs. Deal Probability



EDA - Correlations

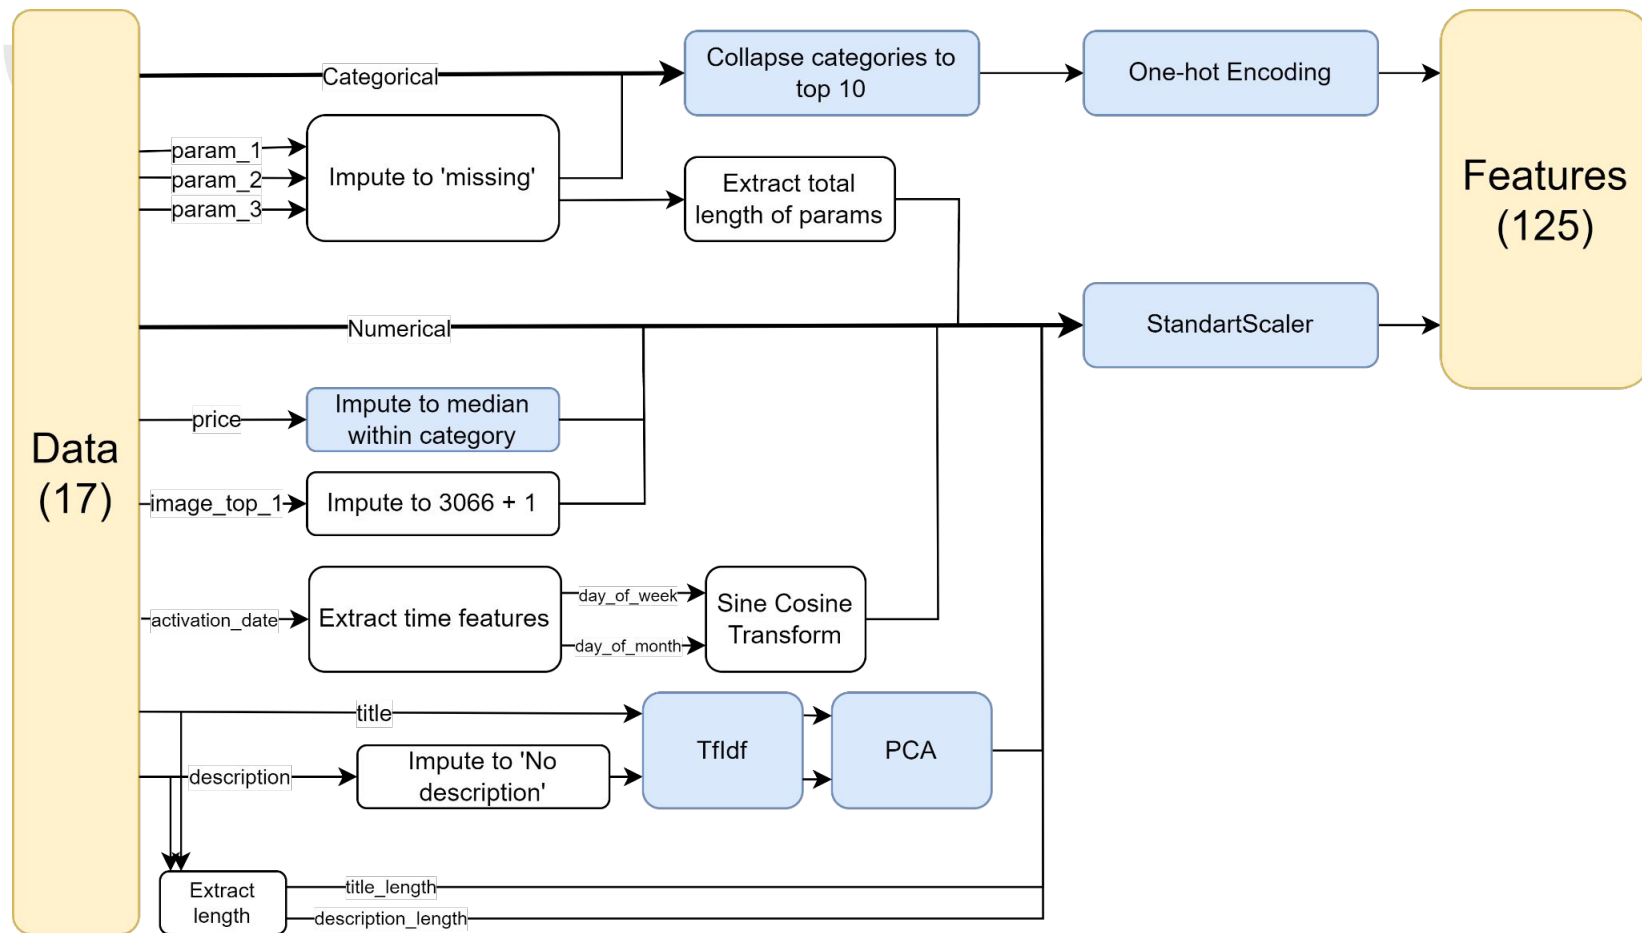




POC

- Simple Linear Regression with our full preprocessing pipeline
- **RMSE: 0.2633**

Data preparation





Airflow Pipeline

Extract data pipeline

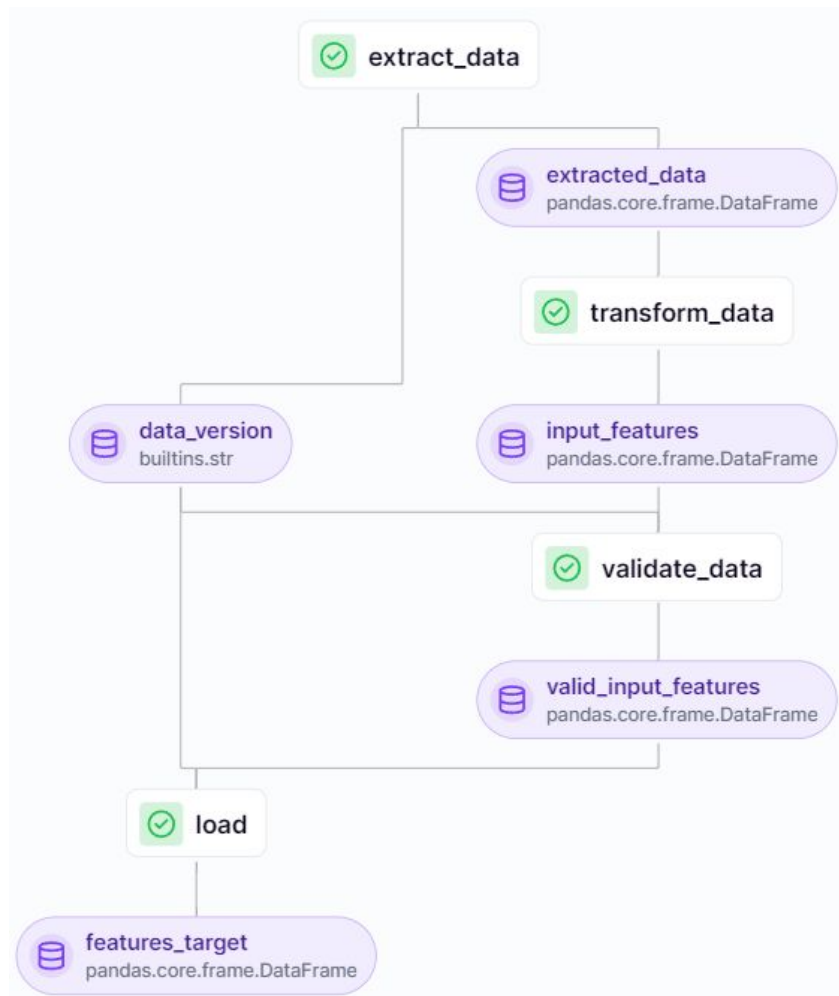


Preprocess data pipeline





ZenML Pipeline





Expectations

```
ex13 = validator.expect_column_values_to_not_be_null(column="description_length", meta={"dimension": "Completeness"})↓
ex15 = validator.expect_column_values_to_be_of_type(column="description_length", type_="float64", meta={"dimension": "Datatype"})↓

ex16 = validator.expect_column_values_to_not_be_null(column="params_length", meta={"dimension": "Completeness"})↓
ex18 = validator.expect_column_values_to_be_of_type(column="params_length", type_="float64", meta={"dimension": "Datatype"})↓


ex19 = validator.expect_column_values_to_not_be_null(column="day_of_week_sin", meta={"dimension": "Completeness"})↓
ex20 = validator.expect_column_values_to_be_between(column="day_of_week_sin", min_value=-1, max_value=1, meta={"dimension": "Range"})↓
ex21 = validator.expect_column_values_to_be_of_type(column="day_of_week_sin", type_="float64", meta={"dimension": "Datatype"})↓

ex22 = validator.expect_column_values_to_not_be_null(column="day_of_week_cos", meta={"dimension": "Completeness"})↓
ex23 = validator.expect_column_values_to_be_between(column="day_of_week_cos", min_value=-1, max_value=1, meta={"dimension": "Range"})↓
ex24 = validator.expect_column_values_to_be_of_type(column="day_of_week_cos", type_="float64", meta={"dimension": "Datatype"})↓

ex25 = validator.expect_column_values_to_not_be_null(column="day_of_month_sin", meta={"dimension": "Completeness"})↓
```




Model engineering - MLP



Parameter	Options	Best Value
Hidden Layer 1 Size	[32, 64, 128]	32
Hidden Layer 2 Size	[16, 32, 64]	16
Hidden Layer 3 Size	[8, 16, 32]	32

Model engineering - ResNet



Parameter	Options	Best Value
Embedding Size	[16, 32, 64, 128]	128
Number of Residual Blocks	[1, 3, 5, 10]	3
Dropout Rate	[0.35, 0.5, 0.75]	0.75



Model Performance

Model	RMSE	MSE	MAE
MLP	0.242	0.0585	0.162
ResNet	0.246	0.0606	0.166



Result Reproducibility

Metric	Values	Average	Variance
MAE	[0.1606, 0.1615, 0.1631, 0.1632, 0.1625]	0.1622	9.67×10^{-7}
MSE	[0.0586, 0.0586, 0.0585, 0.0586, 0.0586]	0.0586	1.28×10^{-9}
RMSE	[0.2421, 0.2421, 0.2419, 0.2420, 0.2420]	0.2420	5.47×10^{-9}


Table 4: MLP Test Metrics for Different Seeds

Metric	Values	Average	Variance
MAE	[0.1683, 0.1589, 0.1578, 0.1659, 0.1804]	0.1663	6.59×10^{-5}
MSE	[0.0597, 0.0607, 0.0628, 0.0592, 0.0607]	0.0606	1.51×10^{-6}
RMSE	[0.2444, 0.2464, 0.2506, 0.2433, 0.2464]	0.2462	6.16×10^{-6}

Table 5: ResNet Test Metrics for Different Seeds

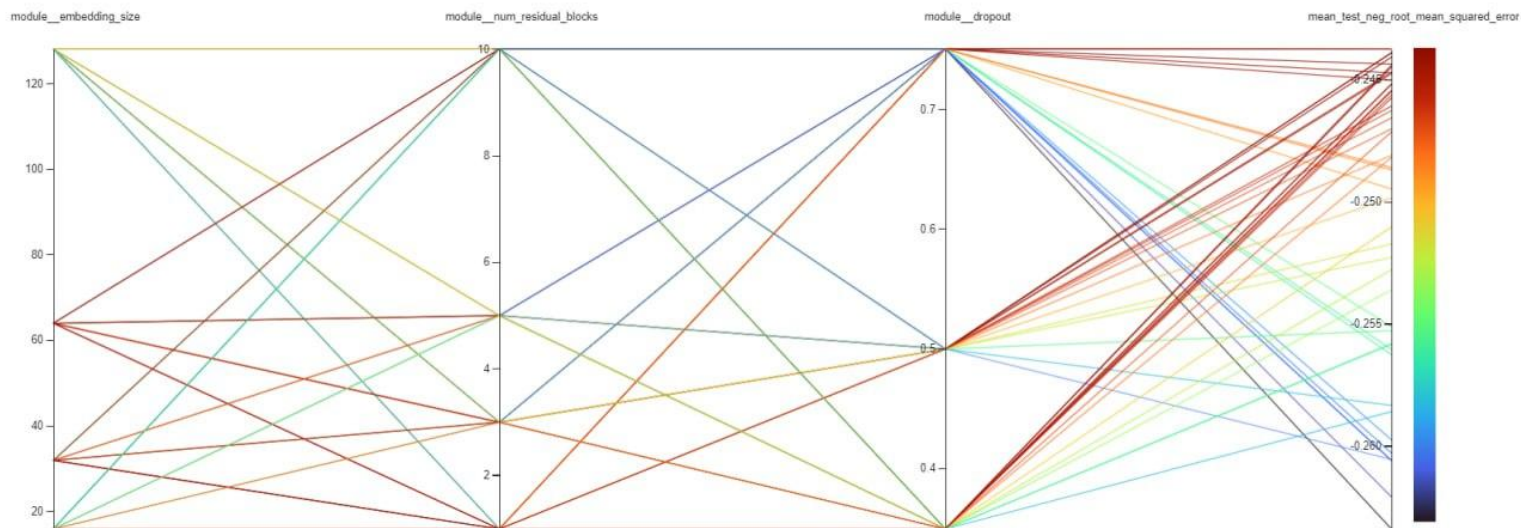


MLP - Parallel Plot





ResNet - Parallel Plot





Model validation

- **Performance Test:** RMSE with a threshold of 0.25
- **Success Criteria:** Achieve an RMSE below 0.25 on unseen data.
- **Result:** The MLP model successfully met the validation criteria.
- **Decision:** Proceed with model deployment.



Validation report of the champion model

https://drive.google.com/file/d/1a9NFoW3XWYYuDmQSyJDjCMXN_W-w-K3a/view?usp=sharing



Model deployment



Deployment Options:

- **Docker:** Packaged the model and dependencies into a Docker image.
- **Flask API:** Developed a custom API for more direct and localized deployment.

User Interface:

- **Gradio:** Built an intuitive GUI for users to input ad details and receive demand predictions.

Inference Hardware:

- **Model Size:** 100 Kb
- **Hardware tested:** CPU: Intel Core i5, RAM: 16GB



Project plan

<https://sharing.clickup.com/9012093001/g/h/8cik829-412/85b8479c837f6cd>



Project collaboration

Data engineer: Ildar Zalialiev

- Setup extraction pipeline
- Setup preparation pipeline using ZenML and Airflow
- Tests and Expectations

Data scientist: Artur Zagitov

- EDA
- Build data preprocessing pipeline
- Build and train models

ML engineer: Artem Nazarov

- Model validation
- Model deployment
- Gradio UI

Tasks	Phase 1	Phase 2	Phase 3	Phase 4	Phase 5
Ildar Zalialiev	50%	50%	20%	20%	10%
Artur Zagitov	40%	40%	40%	30%	20%
Artem Nazarov	10%	10%	40%	50%	70%
Total	1	1	1	1	1



Challenges and lessons learned

- Main technical challenge: Deploying Pytorch+Skorch model to Docker
- Dependencies

```
class WrappedNeuralNetRegressor(NeuralNetRegressor):  
    ... def __init__(self, *args, **kwargs):  
    ...     super(WrappedNeuralNetRegressor, self).__init__(*args, **kwargs)  
    ...  
    ... def prepare_data(self, X):  
    ...     if isinstance(X, pd.DataFrame):  
    ...         return X.values.astype(np.float32)  
    ...     return X  
    ...  
    ... def prepare_target(self, y):  
    ...     if isinstance(y, pd.Series):  
    ...         return y.values.astype(np.float32).reshape(-1, 1)  
    ...     return y  
    ...  
    ... def fit(self, X, y, **fit_params):  
    ...     X = self.prepare_data(X)  
    ...     y = self.prepare_target(y)  
    ...     return super(WrappedNeuralNetRegressor, self).fit(X, y, **fit_params)  
    ...  
    ... def predict(self, X):  
    ...     X = self.prepare_data(X)  
    ...     return super(WrappedNeuralNetRegressor, self).predict(X)  
    ...  
    ... def score(self, X, y):  
    ...     X = self.prepare_data(X)  
    ...     y = self.prepare_target(y)  
    ...     return super(WrappedNeuralNetRegressor, self).score(X, y)
```



Demo